

Extraction d'Expressions Temporelles : État de l'art et Évaluation

Comparaison des approches et évaluation de BERT

Amar MERABTI
Lynda HAMMOUCHE

Introduction & Context

Le défi : extraire et structurer les informations temporelles dans les textes

Applications clés :

- Médical : reconstruction du parcours de soin
- Historique : frises chronologiques automatiques
- Juridique/Financier : suivi d'évolution de documents

Objectif : comparer les approches et évaluer BERT

Etat de l'art : Les Trois Grandes Approches

- ➔ • **Rule-based (HeidelTime)** : règles linguistiques manuelles
- ➔ • **Hybride (PTime)** : patterns automatiques + optimisation statistique
- ➔ • **Neuronale (BERT)** : apprentissage profond, transformers

HeidelTime - Rule Based

Étapes du processus :

1. Extraction par règles : expressions régulières (regex) pour détecter les motifs temporels, Utilisation d'indices linguistiques POS tags)

2. Structure de traitement :

- Expression temporelle = Triplet (Texte, Type, Valeur normalisée)
- Types : Date, Heure, Durée, Set

3. Normalisation :

- Conversion au format TimeML standardisé.
- Attribution de valeurs sémantiques cohérentes.

PTime - Systèmes Hybrides

Génération Automatique de Patterns

Processus d'apprentissage :

- Apprentissage direct depuis les données annotées.
- Extraction automatique des séquences de Tokens.
- Constitution d'un large ensemble de patterns candidats.

EBMC (Extended Budgeted Maximum Coverage)

Objectif : sélectionner la meilleure couverture de pattern , afin de maximiser le F1score.

Méthode : Algorithme glouton (Greedy)



BERT - Approches Neuronales

Approche 1 :

- **Token Classification** : 3 variantes
 - ➔ **Vanilla BERT (standard)**
 - ➔ **DateBERT (+ date document)**
 - ➔ **BERT-CRF (Conditional Random Field)**

Approche 2 :

- **Seq2Seq (Génération) :**
- **RoBERTa2RoBERTa (R2R) = Meilleur modèle**



Comparaison - Etat de l'art

Table 2: Precision, Recall and F1 scores for strict and relaxed matches, as well as the type classification F1 on TempEval-3. Two highest values are highlighted.

Model	Strict Detection			Relaxed Detection			Type
	Pr.	Re.	F1	Pr.	Re.	F1	
HeidelTime	83.97	79.71	81.78	93.13	88.41	90.71	78.07
UWTime	86.10	80.40	83.10	94.60	88.40	91.40	85.40
Syntime	91.49	93.48	92.47	93.62	95.65	94.62	n/a
TOMN	92.59	90.58	91.58	95.56	93.48	94.51	n/a
PTime	85.19	83.33	84.25	92.59	90.58	91.58	n/a
BERT-time	92.48	89.13	90.77	96.24	92.75	94.46	n/a
BERT-base	80.70	78.84	79.76	91.54	89.42	90.46	84.89
DateBERT	80.96	79.42	80.17	91.59	89.85	90.70	85.73
BERT-CRF	80.87	79.41	80.12	91.03	89.42	90.20	85.10
BERT-base _p	81.83	79.56	80.67	91.37	88.84	90.08	82.00
DateBERT _p	81.67	79.42	80.53	91.66	89.13	90.37	83.17
BERT-CRF _p	81.87	79.85	80.85	91.53	89.27	90.39	82.02
R2R _p	96.03	94.78	95.40	99.12	97.82	98.46	87.23
B2B _p	94.00	72.75	82.02	100	77.39	87.25	79.08
BERT-base*	80.36	84.20	82.23	89.21	93.47	91.29	84.64
DateBERT*	82.72	85.79	84.21	90.95	94.35	92.60	86.21
BERT-CRF*	78.08	82.46	80.12	89.04	94.05	91.48	85.41
BERT-base* _p	79.27	85.80	82.39	86.62	93.76	90.05	83.09
DateBERT* _p	80.31	85.65	82.89	91.16	94.20	91.16	84.01
BERT-CRF* _p	80.74	84.49	82.57	89.89	94.05	91.92	82.43
R2R* _p	96.37	96.37	96.37	100	100	100	90.43
B2B* _p	94.11	81.01	87.07	100	86.09	92.52	83.79

Table 3: Precision, Recall and F1 scores for strict and relaxed matches, as well as the type classification F1 on Tweets. Two highest values are highlighted.

Model	Strict Detection			Relaxed Detection			Type
	Pr.	Re.	F1	Pr.	Re.	F1	
HeidelTime	89.58	72.88	80.37	95.83	77.97	85.98	84.38
UWTime	88.54	72.03	79.44	96.88	78.81	86.92	79.43
Syntime	89.20	94.49	91.77	93.20	98.78	95.88	n/a
TOMN	90.69	94.51	92.56	93.52	97.47	95.45	n/a
PTime	92.92	94.09	93.50	97.92	99.16	98.53	n/a
BERT-time	92.21	94.94	93.56	95.08	97.89	96.47	n/a
BERT-base	88.81	91.64	90.20	94.44	97.47	95.93	94.60
DateBERT	90.15	91.81	90.97	95.37	97.13	96.24	95.07
BERT-CRF	88.64	90.12	89.37	95.77	97.38	96.57	95.14
BERT-base _p	87.86	83.96	85.86	95.47	91.24	93.30	92.34
DateBERT _p	88.73	87.00	87.86	95.61	93.75	94.67	93.31
BERT-CRF _p	86.76	85.14	85.94	95.10	93.33	94.20	91.22
R2R _p	94.15	91.05	92.57	99.30	96.03	97.63	94.12
B2B _p	93.88	81.51	87.26	100	86.83	92.95	90.24
BERT-base*	90.66	90.04	90.34	96.18	95.52	95.85	93.30
DateBERT*	90.84	89.45	90.14	96.67	95.19	95.92	93.03
BERT-CRF*	89.68	88.01	88.84	97.33	95.52	96.42	94.21
BERT-base* _p	87.78	87.84	87.81	94.68	94.68	94.64	91.10
DateBERT* _p	87.82	88.10	87.95	95.22	95.52	95.36	93.51
BERT-CRF* _p	87.89	85.76	86.81	96.33	93.98	95.14	93.00
R2R* _p	95.22	94.26	94.74	99.82	98.81	99.32	97.11
B2B* _p	94.35	83.20	88.43	100	88.18	93.72	90.49

Source : BERT got a Date: Introducing Transformers to Temporal Tagging



Comparaison - Etat de l'art

TABLE 1 – Comparaison des différentes approches d'extraction temporelle

Critères	HeidelTime (Rule-based)	PTime (Hybride)	BERT (Neuronal)
Hardware / Ressources	Faible (CPU uniquement). Très léger.	Moyen (CPU/RAM).	Élevé (GPU recommandé pour l'inférence).
Interprétabilité	Totale : On peut lire et modifier la règle exacte.	Partielle : Les motifs sont générés mais lisibles.	Nulle (Boîte noire) : Les poids des neurones sont illisibles.
Dépendance aux données	Aucune (besoin d'expertise linguistique).	Modérée (besoin d'un corpus pour générer les motifs).	Forte : Nécessite des milliers d'exemples annotés.
Langues supportées	Excellente (200+ langues grâce à sa communauté).	Limitée aux langues du corpus d'entraînement.	Multilingue (si utilisation de mBERT).
Adaptabilité (Domaine)	Difficile (réécriture manuelle des règles nécessaire).	Bonne (génération automatique de motifs).	Excellente par fine-tuning (ex : médical, juridique).

Notre Évaluation - Méthodologie

Modèle testé :

temporal_tagger_BERT_tokenclassifier

Trois corpus différents :

- Textes historiques (WikiWars)
- Documents médicaux (MTSamples Emergency)
- Tweets (Syntime)

Pipeline :

Ingestion → Extraction BERT → Alignement Gold Standard → Métriques

Deux évaluations :

Détection + Classification

Evaluation sur les données historiques

Data : WikiWars

Source et Nature :

- Corpus de référence
- Textes issus de Wikipédia
- Gold Standard
- Disponible publiquement*

Documents Utilisés :

- World War I (WW1) : 1914-1918
- World War II (WW2) : 1939-1945
- French Revolution : 1789-1799
- Algerian War : 1954-1962

`In the early morning hours of November 1, 1954,`

`In <TIMEX2 val="1954-11-01TMO">the early morning hours of November 1, 1954</TIMEX2>,`

Méthodologie 1/2

1- Ingestion des Données

- Extraction : texte brut et annotations
- Segmentation en phrases
- Deux flux de données distincts

2- Extraction Automatique BERT

- Input : texte brut
- Analyse phrase par phrase
- Output : entités prédites avec type

3- Alignement Gold ↔ Prédictions

- Normalisation des textes (minuscules, ponctuation)
- Matching exact basé similarité
- Catégorisation : TP, FP, FN

4- Calcul des Métriques

- Détection : localiser les expressions
- Classification : assigner le bon type
- Métriques : Précision, Rappel, F1-Score

Méthodologie 2/2


Les résultats du traitement sont exportés vers base de données SQLite

	id	predicted_text	predicted_type	predicted_context	gold_text	gold_type	gold_value	entity_matched	type_matched	status
	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre
1	1	the early morning hours of november ...	TIME	Beginning of hostilities In the early ...	the early morning hours of November...	TIME	1954-11-01TMO	1	1	TRUE_POSITIVE
2	2	all - saints ' day	DATE	Beginning of hostilities In the early ...	N/A (Inventée)	N/A	N/A	0	0	FALSE_POSITIVE
3	3	only a few months before	DATE	" It was the reaction of Premier Pierr...	only a few months before	SET	XXXX-XX	1	0	TRUE_POSITIVE
4	4	five years	DURATION	" It was the reaction of Premier Pierr...	five years	DURATION	P5Y	1	1	TRUE_POSITIVE
5	5	november 12	DATE	On November 12, he declared in the ...	November 12	DATE	1954-11-12	1	1	TRUE_POSITIVE
6	6	a long time	DATE	They have been French for [a long ...	a long time	UNKNOWN	NULL	1	0	TRUE_POSITIVE
7	7	may 8, 1945	DATE	" At first, and despite the May 8, 194...	May 8, 1945	DATE	1945-05-08	1	1	TRUE_POSITIVE
8	8	1952	DATE	This terrorist group engaged in anti-...	1952	DATE	1952	1	1	TRUE_POSITIVE
9	9	the first year of the war	DURATION	During [the first year of the war], ...	the first year of the war	DURATION	P1Y	1	1	TRUE_POSITIVE
10	10	april 1956	DATE	In April 1956, Abbas flew to Cairo, ...	April 1956	DATE	1956-04	1	1	TRUE_POSITIVE
11	11	the past	DATE	This action brought in many évolués ...	the past	DURATION	PAST_REF	1	0	TRUE_POSITIVE
12	12	the years of the war of independence	DURATION	"Café wars," resulting in nearly 5,000...	the years of the War of Independence	DURATION	P9Y	1	1	TRUE_POSITIVE


Enfin, des visualisations graphiques sont générées automatiquement

Résultats et Analyses

Détail des Performances : DÉTECTION



Détail des Performances : CLASSIFICATION



Observations clés

- Détection > Classification
- Stabilité remarquable entre documents
- French Revolution : challenge en classification

Evaluation sur les données médicales

Data : MTSamples

Source et Nature :

- une collection de rapports médicaux transcrits pour plusieurs spécialités cliniques.
- Double annotations manuelles.

Documents Utilisés :

- la spécialité Emergency (Urgences).
➡ 75 fichiers texte

Exemple : restart the Angiomax once he is back from the OR tomorrow. Currently, his INR is 2.2.

102-consult-icumanagement tomorrow tomorrow date date DCT+P1D DCT + P1D 7868 7876 7868 7876

Méthodologie 1

1- Ingestion des donnees et Extraction Automatique BERT

- Input : texte brut
- Analyse phrase par phrase
- Output : entités prédites avec type et les indices du debut et fin de l'entité

2 - Evaluation

- **Détection :**

- **Exact match** : correct uniquement si les bornes début/fin correspondent exactement à l'annotation humaine.

- **Souple** : correct dès qu'il existe un chevauchement entre les spans prédits et annotés

- **Classification** : Evaluation des expressions correctement detectees
le type prédit est identique à celui de l'annotation humaine correspondante



Méthodologie 2/2







Les résultats du traitement sont exportés vers base de données SQLite

	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre
1	today	date	176.0	181.0	0.999050438404083	today	date	176.0	181.0	1	1.0	HISTORY OF PRESENT ILLNE
2	two hours	duration	191.0	200.0	0.9640324111575317	two hours	duration	191.0	200.0	1	1.0	Two hours prior to presentat
3	now	date	344.0	347.0	0.99841034412384	now	date	344.0	347.0	1	1.0	Two hours prior to presentat
4	four to five months	duration	309.0	328.0	0.918516099452972	four to five months	duration	309.0	328.0	1	1.0	The patient has not used ...
5	february of 1995	date	1078.0	1094.0	0.999393463134766	in february of 1995	date	1075.0	1094.0	1	1.0	PAST MEDICAL HISTORY:...
6	last night	time	164.0	174.0	0.999430298805237	last night	date	164.0	174.0	0	1.0	Difficulty breathing began las
7	10 / 04 / 2007	date	500.0	510.0	0.998611330986023	10/04/2007	date	500.0	510.0	1	1.0	He has been seen here twice
8	10 / 20 / 2007	date	515.0	525.0	0.978645145893097	10/20/2007	date	515.0	525.0	1	1.0	He has been seen here twice
9	over one hour	duration	2574.0	2587.0	0.864895820617676	one hour	duration	2579.0	2587.0	1	1.0	We gave 20 mL/kg bolus of n
10	one hour	duration	3287.0	3295.0	0.999247550964356	one hour	duration	3287.0	3295.0	1	1.0	The child was monitored clos
11	90 minutes	duration	3621.0	3631.0	0.941009640693665	90 minutes	duration	3621.0	3631.0	1	1.0	After 90 minutes of continuo

Enfin, des visualisations graphiques sont générées automatiquement


Evaluation sur les données médicales

Exact match :



Evaluation sur les données médicales

Evaluation souple



Evaluation sur les données Tweets

Data : dépôt Syntime

Source et Caractéristiques :

- Corpus Syntime (GitHub)*
- Tweets annotés manuellement
- Format : TimeML / TIMEX3
- Langage informel, fragmenté, abréviations

Processus de Prétraitement :

- Extraction : regex
- Version brute : input modèle
- Version annotée : évaluation
- DataFrame unifié : texte_brut, texte_annoté, source_file

```
Gonna be so busy with school starting by <TIMEX3 type="DATE">monday</TIMEX3>
```

```
Gonna be so busy with school starting by monday.
```

*<https://github.com/xszhong/syntime/tree/master/syntime>

Méthodologie 1/2

1- Chargement et Vérification

- Import du DataFrame prétraité
- Colonnes requises (texte_brut, texte_annoté)
- Nombre de tweets à traiter

3- Extraction Automatique BERT

- Pour chaque tweet, BERT retourne :
Entité détecté, Type prédit
- Création liste entités_prédites

2- Extraction Gold Standard

- Parsing <TIMEX3> dans texte_annoté
- Création liste "entités_gold"

4- Evaluation

- Détection : matching textuel
- Classification : vérification type
- Deux modes : Strict et Souple


Méthodologie 2/2

Les résultats du traitement sont exportés vers base de données SQLite

	id	predicted_text	predicted_type	gold_text	gold_type	gold_value	entity_matched	type_matched	status
	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	
1	1	saturday	DATE	Saturday	DATE	2011-11-26-WXX-6	1	1	TRUE_POSITIVE
2	2	today	DATE	today	DATE	2011-11-26	1	1	TRUE_POSITIVE
3	3	this weekend	DATE	this weekend	DATE	2013-W43-WE	1	1	TRUE_POSITIVE
4	4	30 sep	DATE	30 Sep.	DATE	2013-09-30	1	1	TRUE_POSITIVE
5	5	morning	TIME	Morning	TIME	2015-03-21TMO	1	1	TRUE_POSITIVE
6	6	21 apr 1030am	TIME	21 Apr 1030am	TIME	2013-04-21T10:30	1	1	TRUE_POSITIVE
7	7	right now	DATE	right now	DATE	PRESENT_REF	1	1	TRUE_POSITIVE
8	8	days	DURATION	days	DURATION	PXD	1	1	TRUE_POSITIVE
9	9	day	DURATION	day	DURATION	P1D	1	1	TRUE_POSITIVE
10	10	now	DATE	now	DATE	PRESENT_REF	1	1	TRUE_POSITIVE
11	11	1	TIME	1hr	DURATION	P1H	1	0	TRUE_POSITIVE
12	12	# #hr	DURATION	1hr	DURATION	P1H	1	1	TRUE_POSITIVE
13	13	11 : 59pm	TIME	1	DATE	2013-11-1	1	0	TRUE_POSITIVE


Calcul des métriques (précision, Rappel, Score-F1) et génération des visualisations

Résultats et Analyses



Evaluation stricte

Evaluation souple



Conclusion

Résultats Clés :

- BERT atteint 93-95% F1 sur textes formels et tweets
- Spécialisation domaine = facteur critique (Tweets 95% vs Médical 75%)
- Détection > Classification systématiquement

Limites :

- Vocabulaires spécialisés non vus pendant l'entraînement
- Frontières d'entités : principal défi

Perspectives :

- Fine-tuning (médical ou autres)
- Extension vers LLMs récents et multilingue

Merci !



Références

- [1] Almasian, S., Aumiller, D., & Gertz, M. (2021). *BERT got a Date : Introducing Transformers to Temporal Tagging*. arXiv preprint arXiv :2109.14927.
- [2] Ding, W., Gao, G., Shi, L., & Qu, Y. (2019). A Pattern-Based Approach to Recognizing Time Expressions. In *Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence (AAAI-19)*, pp. 6335–6342.
- [3] Mazur, P., & Dale, R. (2010). WikiWars : A New Corpus for Research on Temporal Expressions. In *Proceedings of the 2010 Conference on Empirical Methods in Natural Language Processing*, pp. 913–922, Cambridge, MA.
- [4] Strötgen, J., & Gertz, M. (2010). HeidelTime : High Quality Rule-based Extraction and Normalization of Temporal Expressions. In *Proceedings of the 5th International Workshop on Semantic Evaluation*, pp. 321–324, Uppsala, Sweden.
- [5] Su, X., Howard, P., & Bethard, S. (2025). Transformer-Based Temporal Information Extraction and Application : A Review. arXiv preprint arXiv :2504.07470.