

Université de Paris Cité

Rapport du Projet

Extraction Temporelle

Réalisé par :

MERABTI Amar

HAMMOUCHE Lynda

2025–2026

Table des matières

1	Introduction	2
2	Les Outils existants	2
2.1	Systèmes basés sur des règles (Rule-based Systems)	2
2.1.1	HeidelTime	2
2.2	Systèmes Hybrides (Hybrid Systems)	3
2.2.1	PTime	4
2.3	Approches Neuronales (Neural Approaches)	4
2.3.1	L'approche BERT	4
2.4	Comparaison des outils	6
2.5	Performances	6
2.6	Synthèse et Perspectives	7
3	Évaluation d'un Système d'Extraction d'Expressions Temporelles	7
3.1	Evaluation sur corpus Historiques	7
3.1.1	Données WikiWars	7
3.1.2	Méthodologie d'évaluation	8
3.1.3	Résultat et analyse	10
3.1.4	Synthèse et Interprétation Globale	12
3.2	Evaluation sur corpus Medical :	12
3.2.1	Dataset MTSamples	12
3.2.2	Méthodologie d'évaluation	13
3.2.3	Résultats et Analyse	14
3.3	Evaluation sur corpus de tweets	15
3.3.1	Données Syntime	15
3.3.2	Méthodologie	17
3.3.3	Résultats et analyse	19
4	Conclusion	20

1 Introduction

Le Traitement Automatique des Langues (NLP - Natural Language Processing) joue aujourd'hui un rôle pivot dans l'exploitation des données textuelles non structurées. Parmi ses défis majeurs, l'extraction d'informations temporelles s'impose comme une tâche fondamentale. Elle ne consiste pas seulement à repérer des dates, mais à comprendre la chronologie des événements pour transformer un récit narratif en une structure de données organisée et exploitable.

Cette capacité de structuration temporelle trouve des applications cruciales dans de nombreux domaines tel que :

Dans le domaine médical : L'analyse des comptes rendus hospitaliers permet de reconstruire le parcours de soin du patient. En identifiant précisément la succession des symptômes, des diagnostics et des traitements, on améliore la qualité de la prise en charge et l'aide à la décision clinique.

Dans le domaine historique : Elle permet de traiter des archives massives pour modéliser des frises chronologiques automatiques, facilitant ainsi la compréhension des dynamiques temporelles à travers les siècles.

Dans l'analyse de documents juridiques ou financiers : Pour suivre l'évolution de contrats ou de rapports d'activité.

L'objectif de ce travail est de mener une étude de l'extraction temporelle. Dans un premier temps, nous réaliserons un état de l'art des technologies actuelles, en comparant différentes approches : les systèmes basés sur des règles linguistiques, les méthodes par expressions régulières et les modèles récents issus du Deep Learning. Dans un second temps, nous mettrons en œuvre et testerons l'un de ces outils afin d'évaluer sa capacité à extraire et modéliser des entités temporelles sous forme de tables structurées.

2 Les Outils existants

L'évolution des systèmes de temporal tagging peut être divisée en trois catégories principales, selon le degré d'utilisation de règles manuelles par rapport à l'apprentissage statistique.

2.1 Systèmes basés sur des règles (Rule-based Systems)

Les approches rule-based s'appuient sur des règles explicites conçues manuellement pour détecter les expressions temporelles. Ces règles combinent des patrons linguistiques, des expressions régulières et des ressources lexicales afin de reconnaître des formes temporelles telles que les dates, les durées ou les fréquences dans un texte.

2.1.1 HeidelTime

Développé par l'Université de Heidelberg en Allemagne, HeidelTime [4] est un système fondé sur des règles conçu pour extraire et normaliser les expressions temporelles dans des documents textuels.

Architecture et Intégration Le système est implémenté en tant que composant UIMA (Unstructured Information Management Architecture). Cela lui permet d'être intégré dans des chaînes de traitement de documents plus larges où les informations circulent via une structure commune appelée CAS (Common Analysis Structure).

Le Processus d'Extraction et de Normalisation HeidelTime traite les expressions temporelles comme des triplets composés de l'expression textuelle, du type (Date, Heure, Durée ou Set) et de la valeur normalisée. Le processus suit généralement ces étapes :

- **Extraction par règles** : Le système utilise des expressions régulières (regex) pour identifier les motifs temporels dans le texte. Ces règles peuvent également s'appuyer sur des indices linguistiques comme les étiquettes de parties du discours (POS tags).
- **Normalisation** : Une fois extraite, l'expression est convertie en une valeur standardisée (format TimeML). HeidelTime utilise des ressources de connaissances (ex : dictionnaires de mois, saisons ou jours fériés) pour attribuer la bonne valeur sémantique.

Gestion des Expressions Complexes Le système distingue trois types d'expressions pour la normalisation :

- **Explicites** : Directement convertibles (ex : "11 mars 1982" devient 1982-03-11).
- **Implicites** : Nécessitent une connaissance externe (ex : "Fête nationale 2010").
- **Relatives** : C'est le défi majeur (ex : "l'année dernière", "en juin"). HeidelTime utilise alors le temps de création du document (DCT) ou une date mentionnée précédemment comme point de référence.

Post-traitement et Désambiguïsation Une fois les règles appliquées, le système effectue deux étapes cruciales :

- **Désambiguïsation linguistique** : Si une expression comme "en juin" est rencontrée, le système analyse le temps des verbes de la phrase pour décider s'il s'agit du mois de juin passé ou futur.
- **Nettoyage** : Il supprime les expressions invalides ou redondantes (par exemple, si "juin" est extrait alors qu'il fait partie de "11 juin", seule l'expression complète est conservée).

Flexibilité de Performance L'utilisateur peut choisir entre deux jeux de règles selon ses besoins :

- Optimisé pour la précision : Pour minimiser les erreurs d'extraction.
- Optimisé pour le rappel : Pour extraire un maximum d'expressions, quitte à inclure quelques erreurs.

2.2 Systèmes Hybrides (Hybrid Systems)

L'approche hybride combine la structure explicite des méthodes à base de règles avec la capacité d'optimisation des modèles d'apprentissage automatique. Contrairement aux modèles neuronaux qui fonctionnent comme des "boîtes noires", l'approche hybride utilise des représentations symboliques (des patrons ou patterns) pour garantir que le résultat soit interprétable par l'humain.

2.2.1 PTime

PTime (Pattern-based Time recognition) [2] est une approche hybride pour la reconnaissance d'expressions temporelles qui allie la transparence des systèmes à base de règles et la puissance d'optimisation de l'apprentissage automatique. PTime repose sur la génération automatique et la sélection statistique de patterns. Cette méthode permet d'extraire des informations temporelles de manière précise tout en garantissant des résultats totalement interprétables et adaptables à différents domaines textuels.

Génération Automatique de Patterns Au lieu de s'appuyer sur des règles écrites à la main par des experts linguistes, PTime apprend les structures directement à partir de données d'entraînement annotées. Pour chaque expression temporelle identifiée dans le corpus, le système extrait et mémorise la séquence de jetons correspondante, créant ainsi un large ensemble de patterns candidats.

Sélection Optimisée par le Modèle EBMC La force de PTime réside dans son algorithme de sélection. Puisque tous les patterns générés ne sont pas pertinents (certains pouvant causer des faux positifs), le système traite la sélection comme un problème d'optimisation mathématique appelé EBMC (Extended Budgeted Maximum Coverage).

- **Objectif** : Maximiser la couverture des expressions correctes (le Gain).
- **Contrainte** : Respecter un budget d'erreurs (le Coût) défini par l'utilisateur via un paramètre de confiance.

Un algorithme glouton (Greedy Algorithm) est ensuite utilisé pour sélectionner le sous-ensemble de patrons le plus efficace, offrant ainsi un équilibre optimal entre précision et rappel.

2.3 Approches Neuronales (Neural Approaches)

Avec l'avènement du Deep Learning, ces approches remplacent les règles manuelles et les traits linguistiques prédéfinis par des architectures de réseaux de neurones profonds. En utilisant des représentations vectorielles (embeddings), ces modèles capturent le contexte sémantique complexe et les dépendances à longue distance dans le texte. L'extraction temporelle est alors traitée comme une tâche d'étiquetage de séquence (sequence tagging).

2.3.1 L'approche BERT

Une illustration concrète de cette avancée est présentée dans l'article "BERT got a Date : Introducing Transformers to Temporal Tagging" (Lange et al., 2020) [1]. Les auteurs y démontrent que le modèle BERT (Bidirectional Encoder Representations from Transformers) peut surpasser les systèmes experts en traitant l'extraction comme une classification de jetons.

Description Générale L'objectif est de surpasser les systèmes classiques basés sur des règles (souvent limités et difficiles à généraliser) en utilisant des modèles de langage pré-entraînés. La solution traite deux tâches simultanément :

- **La détection** : Identifier les segments de texte qui correspondent à une expression temporelle.

- **La classification** : Assigner un type TIMEX3 à chaque expression (DATE, TIME, DURATION ou SET).

Architectures Proposées Les auteurs ont exploré deux approches principales :

A. Classification de Jetons (Token Classification)

Cette approche utilise le modèle BERT comme base. Chaque mot (ou "token") reçoit une étiquette selon un schéma BIO étendu (Begin, Inside, Outside). Trois variantes ont été testées :

- **Vanilla BERT** : Une tête de classification linéaire standard au-dessus de BERT.
- **DateBERT** : Intègre la date de création du document comme information supplémentaire via une couche d'encodage spécifique, afin de mieux comprendre les références relatives (ex : "aujourd'hui").
- **BERT-CRF** : Ajoute une couche Conditional Random Field (CRF) pour optimiser la cohérence des séquences d'étiquettes prédites.

B. Génération de Texte (Seq2Seq)

Ici, la tâche est formulée comme une traduction : le texte brut est transformé en texte balisé (format XML). L'architecture est un encodeur-decoder (type Transformer). Le modèle le plus performant est RoBERTa2RoBERTa (R2R), où l'encodeur et le décodeur sont initialisés avec le modèle RoBERTa.

Processus d'Entraînement : Le "Pre-pretraining" Pour pallier le manque de données étiquetées manuellement, les auteurs ont mis en place une stratégie en trois étapes :

1. **Pré-entraînement classique** : Utilisation des poids publics de BERT ou RoBERTa.
2. **Pré-entraînement supervisé "faible" (Weakly-supervised)** : Le modèle est d'abord entraîné sur un corpus massif (1 million de paragraphes) étiqueté automatiquement par un système expert existant (HeidelTime). Cela permet au modèle de se familiariser avec les structures temporelles complexes.
3. **Fine-tuning** : Ajustement final sur des jeux de données de référence de haute qualité (comme TempEval-3).

2.4 Comparaison des outils

TABLE 1 – Comparaison des différentes approches d’extraction temporelle

Critères	HeidelTime (Rule-based)	PTime (Hybride)	BERT (Neuronal)
Hardware / Ressources	Faible (CPU uniquement). Très léger.	Moyen (CPU/RAM).	Élevé (GPU recommandé pour l’inférence).
Interprétabilité	Totale : On peut lire et modifier la règle exacte.	Partielle : Les motifs sont générés mais lisibles.	Nulle (Boîte noire) : Les poids des neurones sont illisibles.
Dépendance aux données	Aucune (besoin d’expertise linguistique).	Modérée (besoin d’un corpus pour générer les motifs).	Forte : Nécessite des milliers d’exemples annotés.
Langues supportées	Excellente (200+ langues grâce à sa communauté).	Limitée aux langues du corpus d’entraînement.	Multilingue (si utilisation de mBERT).
Adaptabilité (Domaine)	Difficile (réécriture manuelle des règles nécessaire).	Bonne (génération automatique de motifs).	Excellente par fine-tuning (ex : médical, juridique).

2.5 Performances

L’évaluation des performances, telle que présentée dans les récents travaux sur BERT-time, met en lumière un basculement technologique : alors que les systèmes hybrides comme PTime ou par règles comme HeidelTime restent compétitifs sur des textes courts (Tweets), la solution basée sur RoBERTa2RoBERTa redéfinit l’état de l’art en matière de classification.

Performance dans la classification des types L’apport principal de la solution basée sur RoBERTa (R2R_p) réside dans sa capacité à distinguer avec finesse les catégories d’expressions (DATE, TIME, DURATION, SET). Là où les modèles neuronaux précédents échouaient souvent face à la rigueur des systèmes experts, R2R_p surpasse l’état de l’art, notamment sur les classes les moins fréquentes.

- **Sur le jeu de données TempEval-3** : Le modèle R2R_p atteint un score F1 de 87,23 pour la classification, surpassant nettement HeidelTime (78,07) et UWTime (85,40).
- **Sur les Tweets** : L’écart est encore plus significatif avec un score de 94,12, contre seulement 84,38 pour HeidelTime.

Performances en détection (Tagging) En ce qui concerne l’identification brute des expressions (le "tagging"), les résultats varient selon la complexité du langage :

- **Textes formels (TempEval-3)** : R2R_p domine largement avec un score F1 de 95,40 en détection stricte, loin devant les 81,78 de HeidelTime.
- **Textes informels (Tweets)** : Sur ce terrain, les approches hybrides comme PTime (93,50) conservent un léger avantage sur R2R_p (92,57). Cela démontre que les

structures par "patterns" de PTime captent parfois mieux les abréviations et les syntaxes particulières des réseaux sociaux.

2.6 Synthèse et Perspectives

L'étude comparative des différentes approches de reconnaissance d'expressions temporelles permet de dégager un compromis entre performance brute et opérationnalité.

- L'approche par règles (HeidelTime) demeure une solution de référence pour sa robustesse et sa légèreté matérielle, bien qu'elle manque de flexibilité face à la diversité sémantique du langage naturel.
- L'approche hybride (PTime) comble cette lacune en automatisant la création de patrons. Elle offre un équilibre remarquable : elle égale presque les modèles de pointe en détection (notamment sur les réseaux sociaux) tout en conservant une structure de décision transparente et explicable.
- L'approche neuronale (R2R_p/ RoBERTa) représente l'état de l'art actuel. Sa capacité à capturer le contexte sémantique lui permet de surpasser tous les autres systèmes dans la classification précise des types (DATE, DURATION, etc.), particulièrement sur les jeux de données complexes comme TempEval-3.

3 Évaluation d'un Système d'Extraction d'Expressions Temporelles

Pour notre étude, nous avons choisi d'évaluer les performances d'un système d'extraction d'expressions temporelles basé sur l'apprentissage profond. Notre choix s'est porté sur le modèle `temporal_tagger_BERT_tokenclassifier` présenté dans l'article "BERT got a Date : Introducing Transformers to Temporal Tagging" (Lange et al., 2020), comme mentionné précédemment.

Ce modèle correspond à l'architecture Vanilla BERT for Token Classification décrite dans l'article original. Il a été entraîné exclusivement sur les ensembles d'entraînement de trois corpus de référence : TempEval-3, Tweets et Wikiwars. Cette approche repose sur l'utilisation de transformers pour la classification de tokens, permettant d'identifier et de catégoriser automatiquement les expressions temporelles dans les textes.

Afin d'évaluer la robustesse et la généralisation du modèle, nous l'avons testé sur trois types de données distinctes : des textes historiques, des documents médicaux et des tweets. Cette diversité de corpus nous permet d'analyser les performances du modèle dans différents contextes linguistiques et domaines d'application.

3.1 Evaluation sur corpus Historiques

3.1.1 Données WikiWars

Dans cette partie, nous avons utilisé le jeu de données WikiWars, un corpus de référence largement employé dans les travaux de recherche sur l'extraction et la normalisation des expressions temporelles. Ce corpus est disponible publiquement via le dépôt GitHub du projet `temporal-extraction` de Semantic Systems :

https://github.com/semantic-systems/temporal-extraction/tree/main/temporal-data/original_datasets/wikiwars

Le corpus WikiWars [3] est composé de textes historiques issus de Wikipédia, décrivant des événements majeurs, et annotés manuellement selon le standard TimeML. Ces annotations constituent un gold standard, ce qui en fait une ressource particulièrement adaptée pour l'évaluation des systèmes d'extraction d'entités temporelles.

Dans ce travail, nous avons utilisé les sous-corpus correspondant aux événements historiques suivants :

- World War I (WW1)
- World War II (WW2)
- French Revolution
- Algerian War

Format des données Les données sont fournies sous forme de fichiers texte enrichis d'annotations temporelles. Les expressions temporelles (dates explicites, périodes, durées ou références temporelles implicites) sont annotées à l'aide de balises XML, généralement de type <TIMEX2>. Chaque entité temporelle est associée à des attributs décrivant sa catégorie (DATE, DURATION, TIME, SET) ainsi que sa valeur normalisée. Ces fichiers consistent alors notre gold standard. À côté de ces fichiers annotés, on retrouve également un fichier qui contient seulement le texte brut, que nous les avons utilisés pour tester le modèle.

Exemple de données :

Un extrait typique du corpus se présente sous la forme suivante :




FIGURE 1 – Texte annoté




FIGURE 2 – Texte brut

3.1.2 Méthodologie d'évaluation

Notre approche repose sur un pipeline automatisé conçu pour extraire, classifier et évaluer des expressions temporelles (dates, durées, fréquences) à partir de corpus de textes historiques. Le processus se divise en quatre étapes principales : l'ingestion des données, l'extraction par le modèle BERT, l'alignement avec le standard de référence (Gold Standard) et enfin l'évaluation quantitative.

1. Ingestion et Préparation des Données Le système prend en entrée le corpus WikiWars. Pour chaque document, deux flux de données sont traités et structurés en parallèle :

- **Le texte brut :** Le contenu narratif est extrait des fichiers sources (format .sgm) et nettoyé (suppression des balises parasites) pour servir de matière première à l'analyse. Le texte est ensuite segmenté en phrases pour respecter la fenêtre de contexte du modèle.

- **Le "Gold Standard" (Vérité Terrain)** : Les annotations manuelles de référence sont extraites des fichiers XML associés. Ces données contiennent le texte exact de l'entité, sa position, ainsi que sa valeur normalisée (souvent au format ISO 8601) et son type sémantique (DATE, DUREE, TEMPS, SET). Cela constitue la base de comparaison infaillible pour notre évaluation.

2. Extraction Automatique via Modèles de Langage Les données sont ensuite passées au modèle BERT. Ce modèle, pré-entraîné pour la classification de tokens, analyse le texte brut phrase par phrase. Il identifie les segments de texte correspondant à des expressions temporelles et prédit leur catégorie sémantique. Chaque entité détectée est associée à son contexte immédiat et à un score de confiance.

3. Alignement et Validation Croisée Une étape cruciale de notre méthodologie consiste à réconcilier les prédictions du modèle avec les annotations de référence. Pour cela, un algorithme d'appariement compare les résultats de BERT avec les entités balisées <TIMEX2> selon la logique suivante :

- **Normalisation** : Afin de garantir une comparaison robuste, les textes extraits et les textes de référence subissent une normalisation syntaxique (mise en minuscules, suppression de la ponctuation superflue et des espaces multiples). Cela évite de pénaliser le modèle pour des différences de formatage mineures.
- **Matching (Appariement)** : Le système compare chaque prédiction aux entités de référence. Dans ce cas on utilise le matching exact pour comparer les entités. Il catégorise chaque résultat en trois classes :
 - Vrais Positifs : Entités correctement détectées (texte similaire) et alignées avec la référence.
 - Faux Positifs : Entités "inventées" par le modèle mais absentes de la référence (sur-détection).
 - Faux Négatifs : Entités présentes dans la référence mais manquées par le modèle (sous-détection).

4. Métriques d'Évaluation La performance du système est mesurée selon deux axes distincts pour nuancer les résultats :

- **Performance de Détection** : Capacité du modèle à repérer la simple présence d'une entité temporelle dans le texte, quel que soit son type.
- **Performance de Classification** : Capacité du modèle, une fois l'entité détectée, à lui attribuer la catégorie sémantique correcte. Par exemple, le système vérifie si une expression comme "trois ans" est bien classée comme une DURÉE et non comme une DATE.

Pour ces deux axes, nous calculons la Précision (fiabilité des prédictions), le Rappel (couverture des entités réelles) et le F1-Score (moyenne harmonique des deux).

5. Consolidation et Visualisation des Résultats Pour clore le processus de traitement, l'intégralité des résultats est exportée vers une base de données relationnelle SQLite. Cette étape garantit la persistance des données et facilite l'analyse comparative entre les différents corpus.

- **Organisation en tables** : La base est structurée en quatre tables distinctes, chacune correspondant à l'un des fichiers historiques traités (Algerian War, WW1, WW2, French Revolution).
- **Contenu des tables** : Chaque table archive de manière granulaire les performances du modèle BERT. Les colonnes permettent de tracer pour chaque entité :
 - Le texte extrait et sa version normalisée.
 - Le type prédit par le modèle versus le type réel (Gold Standard).
 - Les métriques de confiance et le statut de validation (Vrai Positif, Faux Positif, etc.).

id	predicted_text		predicted_type		predicted_context		gold_text		gold_type		gold_value		entity_matched	type_matched		status
	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter					
1	1	the early morning hours of november ...	TIME	Beginning of hostilities. In the early ...	the early morning hours of November...	TIME	1954-11-01TMO	1	1	TRUE_POSITIVE						
2	2	all - saints' day	DATE	Beginning of hostilities. In the early ...	N/A (Inventée)	N/A	N/A	0	0	FALSE_POSITIVE						
3	3	only a few months before	DATE	" It was the reaction of Premier Pierr...	only a few months before	SET	XXXX-XX	1	0	TRUE_POSITIVE						
4	4	five years	DURATION	" It was the reaction of Premier Pierr...	five years	DURATION	PSY	1	1	TRUE_POSITIVE						
5	5	november 12	DATE	On November 12, he declared in the ...	November 12	DATE	1954-11-12	1	1	TRUE_POSITIVE						
6	6	a long time	DATE	They have been French for [a long ...	a long time	UNKNOWN	NULL	1	0	TRUE_POSITIVE						
7	7	may 8, 1945	DATE	" At first, and despite the May 8, 194...	May 8, 1945	DATE	1945-05-08	1	1	TRUE_POSITIVE						
8	8	1952	DATE	This terrorist group engaged in anti...	1952	DATE	1952	1	1	TRUE_POSITIVE						
9	9	the first year of the war	DURATION	During [the first year of the war], ...	the first year of the war	DURATION	P1Y	1	1	TRUE_POSITIVE						
10	10	april 1956	DATE	In April 1956, Abbas flew to Cairo, ...	April 1956	DATE	1956-04	1	1	TRUE_POSITIVE						
11	11	the past	DATE	This action brought in many evolutions ...	the past	DURATION	PAST_REF	1	0	TRUE_POSITIVE						
12	12	the years of the war of independence	DURATION	"Café wars," resulting in nearly 5,000...	the years of the War of Independence	DURATION	P9Y	1	1	TRUE_POSITIVE						

FIGURE 3 – Aperçu de la base

Cette structuration permet d'effectuer des requêtes SQL complexes pour isoler, par exemple, les types d'entités les plus souvent confondus par le modèle ou pour extraire des statistiques personnalisées par document.

Enfin, des visualisations graphiques (matrices de confusion, histogrammes de distribution des types et scores de performance) sont générées automatiquement pour chaque document traité afin de faciliter l'analyse qualitative des résultats.

3.1.3 Résultat et analyse

Cette section présente les performances obtenues par notre pipeline sur quatre corpus distincts du dataset WikiWars : la Guerre d'Algérie, la Première Guerre mondiale (WW1), la Seconde Guerre mondiale (WW2) et la Révolution française.

Le graphique suivant récapitule les scores des métriques pour les deux tâches critiques : la Détection (localisation de l'entité) et la Classification (identification du type : DATE, DUREE, etc.).




FIGURE 4 – Résultat de l'évaluation sur le corpus historique

Analyse de la Détection D'une manière générale, le modèle affiche une excellente capacité à repérer les entités temporelles dans le flux textuel.

- **Un équilibre optimal (Précision vs Rappel) :** On observe une quasi-parité entre la Précision (moy. 94,0%) et le Rappel (moy. 93,4%). Cela démontre que le modèle est "équilibré" : il ne souffre ni d'hallucinations massives (peu de faux positifs), ni d'une trop grande sélectivité (peu d'oublis).
- **Stabilité des résultats :** Le F1-Score de détection reste très stable, oscillant entre 92,05% (WW1) et 94,98% (Algerian War). Cette régularité prouve que l'architecture BERT est capable de s'adapter à des contextes historiques variés (colonisation, guerres mondiales, révolution) sans perte majeure d'efficacité.
- **Gestion du bruit :** La Précision particulièrement haute sur Algerian War (95,35%) montre que le modèle distingue très clairement le texte narratif des entités temporelles, ne générant que 6 faux positifs sur l'ensemble du document.

Analyse de la Classification La classification des types (déterminer si une entité est une DATE, une DURÉE, etc.) s'avère, comme attendu, plus nuancée que la simple détection.

- **Le paradoxe du Rappel élevé :** Fait marquant, le Rappel de classification reste très élevé sur tous les fichiers (moy. 92,6%), dépassant même souvent la précision. Cela signifie que lorsque le modèle doit qualifier une entité, il parvient à couvrir presque toutes les catégories présentes, mais manque parfois de finesse dans son choix final.

- **Le défi de la Précision sur la Révolution française** : Ce fichier enregistre la plus basse Précision de type (83,13%). Bien que le modèle détecte parfaitement les entités (Rappel de 93,88%), il se trompe de catégorie dans 28 cas. L’usage de termes temporels liés au calendrier révolutionnaire ou à des contextes politiques anciens semble créer une ambiguïté sémantique que le modèle peine à trancher.
- **L’excellence systémique sur WW2** : Le fichier WW2 se distingue avec une Précision de type de 94,27%. La standardisation des rapports militaires de la Seconde Guerre mondiale offre des indices contextuels forts qui permettent au modèle de valider le type de l’entité avec une certitude quasi-maximale

3.1.4 Synthèse et Interprétation Globale

En consolidant l’ensemble des données, le pipeline affiche une moyenne globale de F1-Score de 93,70% en détection et 90,63% en classification.

- **Fiabilité de l’extraction** : Avec une Précision globale élevée, le système peut être utilisé en autonomie pour l’indexation de bases de données historiques : les informations extraites sont fiables et nécessitent peu de correction manuelle.
- **Interprétation de l’écart** : L’écart de performance entre la détection et la classification souligne que la difficulté ne réside pas dans la vue de l’entité (morphologie), mais dans sa compréhension (sémantique)..
- **Pistes d’amélioration** : Le point faible identifié réside dans la chute de précision lors du typage sur certains corpus. Un fine-tuning plus spécifique sur des documents du XVIIIe siècle ou l’ajout de règles de post-traitement basées sur des dictionnaires de termes historiques permettrait de réduire les 28 erreurs de type constatées sur la Révolution française.

3.2 Evaluation sur corpus Medical :

3.2.1 Dataset MTSamples

Les données proviennent de l’article de Viani et al. (2019, BIONLP) : "Annotating Temporal Information in Clinical Notes for Timeline Reconstruction", Ce corpus est disponible publiquement via le dépôt GitHub : <https://github.com/medesto/timeline-reconstruction/blob/master/MTSamples-annotations/README>

Le corpus source est MTSamples (www.mtsamples.com), une collection de rapports médicaux transcrits pour plusieurs spécialités cliniques. Dans le cadre de ce travail, nous utilisons la spécialité Emergency (Urgences), qui se compose de 75 fichiers texte correspondant à des notes cliniques rédigées en langage naturel. Ces documents contiennent de nombreuses références temporelles explicites et implicites, typiques du domaine médical d’urgence.

Les documents ont été doublement annotés par deux annotateurs (un anglophone natif étudiant, un chercheur non-natif) pour identifier cinq types d’expressions temporelles inspirés de TimeML : Date, Time, Duration, Frequency, Age related .

Dans notre travail, nous nous sommes concentrés sur la détection de Date, Time, Duration et Set (qui correspond à Frequency).

Les annotations manuelles sont fournies dans un fichier `all_annotations.txt`. Chaque ligne de ce fichier correspond à une expression temporelle annotée et contient notamment :

- le nom du document source.

- le type de l’expression temporelle.
- les offsets de début et de fin dans le document,
- ainsi que le contexte textuel associé.

3.2.2 Méthodologie d’évaluation

L’évaluation du modèle est réalisée en comparant les prédictions produites automatiquement aux annotations manuelles du corpus, en tenant compte de la double annotation. Une prédiction est considérée comme correcte si elle correspond à au moins une des deux annotations humaines disponibles pour une même expression temporelle.

L’évaluation est conduite selon deux axes complémentaires : la détection et la classification.

Détection des expressions temporelles Une prédiction est considérée comme correcte en détection si les offsets (start, end) prédits correspondent à ceux fournis par l’un des deux annotateurs pour le même document.

Deux stratégies de correspondance sont utilisées :

- **Exact match** : La prédiction est correcte uniquement si les offsets de début et de fin correspondent exactement à ceux d’un annotateur humain.
- **Overlap** : La prédiction est considérée comme correcte dès lors qu’il existe un chevauchement non nul entre les offsets prédits et ceux d’au moins un annotateur. Un score de chevauchement est alors calculé à partir de la longueur commune entre les spans prédits et annotés, normalisée par la longueur maximale des deux segments.

Classification des expressions temporelles La tâche de classification est évaluée uniquement sur les expressions correctement détectées. Elle consiste à vérifier si le type temporel prédit (Date, Time, Duration ou Frequency) correspond au type annoté par l’annotateur humain associé au span retenu.

Ainsi, une prédiction est considérée comme correcte en classification si :

- les offsets correspondent (exact match ou overlap),
- et le type prédit est identique à celui de l’annotation humaine correspondante.

Mesures d’évaluation Pour chacune des tâches (détection et classification), nous calculons les métriques classiques :

- Précision (Precision),
- Rappel (Recall),
- F-mesure (F1-score).

Ces métriques sont calculées de manière globale sur l’ensemble des documents du corpus, et non document par document, afin d’obtenir une évaluation globale des performances du modèle.

3.2.3 Résultats et Analyse




FIGURE 5 – Resultat de l'évaluation du corpus medical avec Exact Match




FIGURE 6 – Resultat de l'évaluation souple du corpus medical

Résultats pour Exact Match Les résultats obtenus avec une stratégie de matching exact montrent des performances modérées du modèle BERT sur le corpus médical d'urgences.

Détection des expressions temporelles : Pour la détection, le modèle atteint 36,8% de précision, 51,3% de rappel et un F1-score de 42,9% (288 TP, 494 FP, 273 FN). Le rappel montre que de nombreuses expressions sont identifiées, tandis que la précision plus faible révèle une tendance à la sur-détection.

Classification : Pour la classification, les scores sont légèrement inférieurs : 31,7% de précision, 47,8% de rappel et 38,1% de F1-score, en raison des confusions entre types temporels et de l'exigence stricte du matching exact.

En résumé, le modèle localise les expressions temporelles plus efficacement qu'il ne les catégorise. Le matching exact, très strict, amplifie l'impact des décalages d'offsets et des variations d'annotation.

Résultats pour Overlap Avec un matching par chevauchement, les performances du modèle augmentent nettement par rapport au matching exact.

Détection : Pour la détection, le modèle obtient une précision de 67%, un rappel de 87,2% et un F1-score de 75,8%. La matrice de confusion (524 TP, 258 FP, 37 FN) montre une forte réduction des faux négatifs, indiquant que la majorité des expressions temporelles sont correctement repérées lorsque de légers décalages d'offsets sont tolérés.

Classification : Concernant la classification, les scores atteignent 55,2% de précision, 84,9% de rappel et 66,9% de F1-score. Ces résultats suggèrent que, une fois l'expression détectée, le modèle assigne généralement le bon type temporel, malgré certaines confusions résiduelles.

Globalement, l'évaluation par overlap apparaît plus adaptée au contexte de double annotation et reflète mieux les capacités réelles du modèle que le matching exact.

Enregistrement des résultats dans une base de données Comme pour les corpus précédents, l'ensemble des prédictions du modèle et leur comparaison avec les annotations de référence ont été sauvegardées dans une base de données SQLite afin de faciliter l'analyse des performances et la consultation des résultats.

	pred_text	pred_type	pred_start	pred_end	pred_score	gold_text	gold_type	gold_start	gold_end	type_match	overlap_score	sentence
	filtre	filtre	filtre	filtre	filtre	filtre	filtre	filtre	filtre	filtre	filtre	filtre
1	today	date	176.0	181.0	0.999050438404083	today	date	176.0	181.0	1	1.0	1.0 HISTORY OF PRESENT ILLNESS:
2	two hours	duration	191.0	200.0	0.964032411575317	two hours	duration	191.0	200.0	1	1.0	Two hours prior to presentation, i
3	now	date	344.0	347.0	0.99841034412384	now	date	344.0	347.0	1	1.0	Two hours prior to presentation, i
4	four to five months	duration	309.0	328.0	0.918516099452972	four to five months	duration	309.0	328.0	1	1.0	The patient has not used ...
5	february of 1995	date	1078.0	1094.0	0.999392463134766	in february of 1995	date	1075.0	1094.0	1	1.0	PAST MEDICAL HISTORY:...
6	last night	time	164.0	174.0	0.999430298805237	last night	date	164.0	174.0	0	1.0	Difficulty breathing began last nig
7	10 / 04 / 2007	date	500.0	510.0	0.99861330986023	10/04/2007	date	500.0	510.0	1	1.0	He has been seen here twice in th
8	10 / 20 / 2007	date	515.0	525.0	0.978645145893097	10/20/2007	date	515.0	525.0	1	1.0	He has been seen here twice in th
9	over one hour	duration	2574.0	2587.0	0.864895820617676	one hour	duration	2579.0	2587.0	1	1.0	We gave 20 ml/kg bolus of norm.
10	one hour	duration	3267.0	3295.0	0.96924755994356	one hour	duration	3267.0	3295.0	1	1.0	The child was monitored closely v
11	90 minutes	duration	3621.0	3631.0	0.941009646693665	90 minutes	duration	3621.0	3631.0	1	1.0	After 90 minutes of continuous ...
12	last month	date	4039.0	4049.0	0.974926948547363	this last month	date	4034.0	4049.0	1	1.0	We both feel that since this child

FIGURE 7 – Aperçu de la base

Conclusion Malgré l'absence de fine-tuning sur des données médicales, le modèle BERT fournit des résultats raisonnables pour la détection et la classification des expressions temporelles dans le corpus Emergency. Les performances restent toutefois limitées, notamment pour la classification stricte des types, ce qui montre qu'une adaptation au domaine médical pourrait encore améliorer significativement les scores.

3.3 Evaluation sur corpus de tweets

3.3.1 Données Syntime

Après avoir évalué le modèle sur des récits historiques et des documents médicaux, il était crucial de tester sa robustesse face à un langage plus contemporain, informel et fragmenté. Pour cela, nous avons testé le modèle sur les données tweets.

Présentation et Ingestion des Données Les données sources proviennent du dépôt Syntime, spécifiquement le jeu de test composé de fichiers au format .tml : <https://github.com/xszhong/syntime/tree/master/syntime>. Ce corpus se distingue radicalement par :

- La brièveté des documents (chaque fichier correspond à un tweet).
- La présence de métadonnées temporelles (date de création du tweet) essentielles pour résoudre les expressions relatives comme "today" ou "yesterday".
- Un langage non conventionnel (abréviations, hashtags, syntaxe simplifiée).

Prétraitement et Nettoyage (Preprocessing) Le passage des fichiers .tml bruts à un format exploitable par le modèle BERT a nécessité un pipeline de prétraitement rigoureux, articulé autour de deux axes :

Extraction et Dualité des données : À l'aide d'une expression régulière, nous avons séparé le contenu de chaque tweet en deux versions :

- **La version brute :** Toutes les balises XML/TIMEX3 sont supprimées pour obtenir le texte tel qu'il apparaîtrait à un utilisateur, servant ainsi d'input direct pour le modèle.
- **La version annotée :** Les balises sont conservées et structurées pour servir de "Gold Standard" lors de l'évaluation.

Normalisation et Alignement : Contrairement aux textes historiques, les tweets contiennent souvent des espaces multiples ou des retours à la ligne incohérents. Le script de prétraitement uniformise ces espaces pour garantir que l'alignement des tokens lors de l'évaluation ne soit pas faussé par des caractères invisibles.

Format Final des Données Après traitement, les données sont structurées dans un DataFrame (tableau) unifié comprenant :

- **Texte brut :** Le tweet nettoyé prêt à être tokenisé.
- **Texte annoté :** Le tweet contenant les balises <TIMEX3> originales.
- **Source :** Le nom du fichier d'origine pour assurer la traçabilité des résultats.

Exemple de donnée traitée Le tableau ci-dessous illustre la transformation opérée par le pipeline de prétraitement sur un échantillon du dataset :

TABLE 2 – Exemple de transformation d'un tweet annoté

État	Contenu du Tweet
Fichier Brut (.tml)	I will be in Paris <TIMEX3 tid="t1" type="DATE" value="2024-05-20">tomorrow</TIMEX3> for a meeting.
Input Modèle (Texte)	I will be in Paris tomorrow for a meeting.
Annotation (Référence)	tomorrow (Type : DATE, Valeur : 2024-05-20)

3.3.2 Méthodologie

Le pipeline d'extraction temporelle développé pour cette partie suit une architecture modulaire et séquentielle qui permet de traiter, d'analyser et d'évaluer automatiquement les expressions temporelles contenues dans les tweets. Cette approche systématique se décompose en plusieurs phases distinctes qui s'enchaînent de manière logique.

Phase de Chargement et Préparation des Données Le pipeline commence par le chargement du corpus de tweets. Ces données arrivent dans un format structuré contenant à la fois le texte brut des tweets et leur version annotée manuellement. Le système vérifie la présence de toutes les colonnes nécessaires au bon déroulement de l'analyse, assurant ainsi l'intégrité des données avant de poursuivre le traitement. Cette étape préparatoire garantit que le pipeline dispose de tous les éléments requis pour effectuer une comparaison rigoureuse entre les annotations humaines et les prédictions automatiques.

Phase d'Extraction des Annotations de Référence Le pipeline extrait ensuite les entités temporelles qui ont été annotées manuellement dans le corpus. Ces annotations, que nous appelons "entités gold", servent de vérité de terrain pour l'évaluation. Le système parse les balises XML TIMEX3 présentes dans les textes annotés, récupérant pour chaque expression temporelle identifiée son texte exact, sa valeur normalisée, son type et son identifiant unique. Cette extraction produit un ensemble de référence complet qui documente toutes les expressions temporelles reconnues par les annotateurs humains.

Phase d'Extraction Automatique par Modèle Transformer La composante centrale du pipeline fait appel à un modèle de deep learning de type BERT spécialisé dans l'identification des expressions temporelles. Ce modèle analyse l'ensemble des tweets en mode batch, ce qui permet de traiter efficacement de grandes quantités de texte. Pour chaque expression temporelle détectée, le système enregistre le texte de l'entité, son type prédit, son contexte d'apparition et un score de confiance. Cette approche automatisée génère un second ensemble d'entités, que nous nommons "entités prédites", qui sera comparé aux annotations de référence.

Phase d'Évaluation Comparative Le pipeline implémente un système d'évaluation à deux niveaux qui permet de mesurer précisément les performances du modèle. La première évaluation se concentre sur la capacité de détection, c'est-à-dire la capacité du système à identifier correctement la présence d'expressions temporelles dans le texte, indépendamment de leur classification. Cette étape calcule des métriques de précision, rappel et F-mesure en appariant les entités prédites aux entités gold selon une logique de correspondance textuelle avec normalisation.

La seconde évaluation examine la classification des types d'entités. Pour les expressions temporelles qui ont été correctement détectées, le système vérifie si le type assigné par le modèle correspond au type annoté manuellement. Cette double évaluation permet de distinguer les erreurs de localisation des expressions temporelles des erreurs de catégorisation.

Le pipeline offre deux modes de correspondance entre les entités prédites et les entités de référence. Le mode strict exige une correspondance textuelle exacte après normalisation, tandis que le mode souple accepte les correspondances partielles où l'une des chaînes

de caractères contient l'autre. Cette flexibilité permet d'explorer l'impact des variations de segmentation sur les résultats d'évaluation.

Phase de Visualisation et Reporting Les résultats de l'évaluation sont ensuite transformés en représentations graphiques qui facilitent l'interprétation des performances. Le système génère des visualisations comparant la distribution des types d'entités entre les annotations humaines et les prédictions automatiques, ainsi que des diagrammes en barres présentant les scores de précision, rappel et F-mesure pour les tâches de détection et de classification. Ces visualisations permettent d'identifier rapidement les forces et les faiblesses du modèle.

Phase de Persistance et Traçabilité La dernière étape du pipeline consiste à sauvegarder l'ensemble des résultats dans une base de données SQLite. Pour chaque paire entité prédite-entité gold, le système enregistre les textes, les types, les valeurs normalisées, ainsi que des indicateurs de correspondance et un statut (vrai positif, faux positif ou faux négatif). Cette structure permet non seulement de conserver une trace complète de l'expérimentation, mais aussi de faciliter des analyses ultérieures plus approfondies, comme l'étude des patterns d'erreurs ou l'identification des cas difficiles.

	id	predicted_text	predicted_type	gold_text	gold_type	gold_value	entity_matched	type_matched	status
	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	Filtre	
1	1	saturday	DATE	Saturday	DATE	2011-11-26-WXX-6	1	1	TRUE_POSITIVE
2	2	today	DATE	today	DATE	2011-11-26	1	1	TRUE_POSITIVE
3	3	this weekend	DATE	this weekend	DATE	2013-W43-WE	1	1	TRUE_POSITIVE
4	4	30 sep	DATE	30 Sep.	DATE	2013-09-30	1	1	TRUE_POSITIVE
5	5	morning	TIME	Morning	TIME	2015-03-21TMO	1	1	TRUE_POSITIVE
6	6	21 apr 1030am	TIME	21 Apr 1030am	TIME	2013-04-21T10:30	1	1	TRUE_POSITIVE
7	7	right now	DATE	right now	DATE	PRESENT_REF	1	1	TRUE_POSITIVE
8	8	days	DURATION	days	DURATION	PXD	1	1	TRUE_POSITIVE
9	9	day	DURATION	day	DURATION	P1D	1	1	TRUE_POSITIVE
10	10	now	DATE	now	DATE	PRESENT_REF	1	1	TRUE_POSITIVE
11	11	1	TIME	1hr	DURATION	P1H	1	0	TRUE_POSITIVE
12	12	#hr	DURATION	1hr	DURATION	P1H	1	1	TRUE_POSITIVE
13	13	11 : 59pm	TIME	1	DATE	2013-11-1	1	0	TRUE_POSITIVE

FIGURE 8 – Aperçu de la base

L'architecture modulaire de ce pipeline présente plusieurs avantages. Elle permet de réexécuter facilement certaines phases de l'analyse sans reprendre l'ensemble du traitement, facilite le débogage en isolant les différentes composantes, et offre la possibilité d'intégrer de nouveaux modèles ou de nouvelles méthodes d'évaluation sans refondre l'ensemble du système. Cette approche méthodique garantit également la reproductibilité des expériences, un élément essentiel de la démarche scientifique.

3.3.3 Résultats et analyse




FIGURE 9 – Resultat de l'évaluation stricte sur le corpus des tweets

L'évaluation du pipeline a été menée selon deux configurations d'appariement : strict (correspondance textuelle exacte) et souple (correspondances partielles acceptées). Les résultats révèlent des performances élevées avec des variations significatives selon le mode choisi.

Distribution des Types d'Entités Le premier graphique révèle une excellente concordance entre les annotations humaines (Gold) et les prédictions du modèle. Les entités de type DATE dominent largement avec environ 164 occurrences dans les annotations de référence et 166 dans les prédictions. Les catégories TIME et DURATION présentent des fréquences similaires (environ 34 et 33 occurrences respectivement), tandis que les entités SET restent minoritaires (environ 6 occurrences). Cette distribution équilibrée démontre que le modèle ne présente pas de biais systématique vers une catégorie particulière.

Performances en Mode Strict En mode d'appariement strict, la détection des entités atteint une précision de 84,6%, un rappel de 88,2%, et une F-mesure de 86,4%. Ces résultats indiquent que le modèle identifie correctement près de 9 expressions temporelles sur 10, avec environ 15% de détections qui ne correspondent pas exactement aux annotations humaines.

Pour la classification, les performances sont remarquables avec une précision de 96,2%, un rappel de 87,8%, et une F-mesure de 91,8%. Lorsque le modèle détecte une entité avec la segmentation exacte, il en identifie correctement le type dans plus de 96% des cas.




FIGURE 10 – Resultat de l'évaluation souple sur le corpus des tweets

Performances en Mode Souple L’adoption du mode souple améliore significativement les scores de détection : précision de 93,5% (+9 points), rappel de 97,5% (+9,3 points), et F-mesure de 95,5% (+9,1 points). Le système manque désormais moins de 3% des expressions temporelles du corpus.

Pour la classification, les résultats évoluent différemment. La précision diminue à 87,9% (-8,3 points) tandis que le rappel augmente à 97,1% (+9,3 points), aboutissant à une F-mesure de 92,3%. Cette inversion s’explique par le fait que les correspondances partielles incluent des cas où la segmentation divergente peut entraîner des différences légitimes de classification.

Analyse Comparative L’écart de performance entre les deux modes révèle que la principale difficulté du système réside dans la délimitation précise des frontières des entités plutôt que dans leur localisation. Les 9 points de différence en F-mesure pour la détection suggèrent que de nombreuses prédictions capturent l’essence de l’expression temporelle sans respecter exactement la segmentation humaine.

Ces résultats positionnent favorablement notre approche avec des F-mesures dépassant 86% en mode strict et 92% en mode souple, démontrant que les modèles BERT spécialisés atteignent des performances proches de l’annotation humaine, même sur des textes informels comme les tweets.

4 Conclusion

Ce travail nous a permis de réaliser une exploration approfondie des techniques d’extraction d’expressions temporelles, depuis les systèmes fondés sur des règles linguistiques jusqu’aux architectures neuronales de dernière génération. L’étude comparative des trois grandes familles d’approches a révélé que chacune possède des atouts spécifiques selon le contexte d’utilisation. Les systèmes à base de règles comme HeidelTime offrent une transparence totale et une légèreté matérielle précieuse pour des déploiements à grande échelle, tandis que les approches hybrides telles que PTime parviennent à combiner intelligemment l’explicabilité des patrons et la puissance de l’optimisation statistique. Les modèles neuronaux basés sur les transformers, représentés ici par l’architecture BERT, se sont imposés comme l’état de l’art actuel grâce à leur capacité remarquable à capturer le contexte sémantique complexe du langage naturel.

L’évaluation systématique du modèle BERT sur trois types de corpus distincts a permis de mesurer concrètement sa robustesse et ses limites. Sur les textes historiques du corpus WikiWars, le modèle a démontré une excellente stabilité avec des scores de détection dépassant les 93% et des performances en classification atteignant 90%. Cette réussite s’explique par la structure narrative relativement formelle des articles encyclopédiques et par la présence d’expressions temporelles clairement contextualisées. Le corpus médical a présenté un défi plus important, révélant que l’absence de spécialisation du modèle pour ce domaine particulier limite significativement ses performances, notamment en mode d’appariement strict où la F-mesure de classification n’atteint que 38%. Toutefois, l’adoption d’une stratégie d’évaluation par chevauchement a permis de constater que le modèle parvient néanmoins à localiser correctement la majorité des expressions temporelles, suggérant que les difficultés résident davantage dans la délimitation précise des frontières d’entités que dans leur identification globale. Enfin, l’évaluation sur les tweets a confirmé la capacité du modèle à s’adapter au langage informel et fragmenté des réseaux sociaux,

avec des performances remarquables dépassant 95% en détection et 92% en classification lorsque des correspondances partielles sont acceptées.

Au-delà des scores quantitatifs, cette étude met en lumière plusieurs enseignements fondamentaux pour le domaine du traitement automatique des langues. Premièrement, la distinction entre la tâche de détection et celle de classification s'avère cruciale pour comprendre les forces et faiblesses d'un système d'extraction. Nos résultats montrent systématiquement que repérer une expression temporelle dans le flux textuel constitue un défi moins ardu que d'en déterminer précisément la catégorie sémantique. Deuxièmement, la méthodologie d'évaluation choisie influence considérablement l'interprétation des performances, comme en témoigne l'écart significatif entre les modes strict et souple sur le corpus médical. Cette observation souligne l'importance d'adopter des stratégies d'évaluation adaptées au contexte applicatif visé et aux tolérances acceptables pour l'utilisateur final. Troisièmement, la spécialisation des modèles par domaine demeure un levier d'amélioration majeur, particulièrement pour des textes techniques comme les comptes rendus médicaux qui emploient un vocabulaire spécialisé et des conventions stylistiques propres.

Les perspectives d'amélioration ouvertes par ce travail sont multiples. Le fine-tuning du modèle BERT sur des corpus médicaux annotés permettrait sans doute d'améliorer substantiellement les performances dans ce domaine. L'intégration de connaissances externes, telles que des dictionnaires de termes historiques ou de calendriers spécialisés, pourrait réduire les erreurs de classification observées sur des corpus comme la Révolution française. L'exploration d'architectures plus récentes, issues de la famille des modèles de langage de grande taille, offrirait également des opportunités intéressantes, notamment pour la normalisation automatique des expressions temporelles en format ISO 8601. Enfin, l'extension de cette étude à d'autres langues que l'anglais constituerait un axe de recherche pertinent, particulièrement pour des langues aux structures temporelles plus complexes ou moins représentées dans les corpus d'entraînement.

En définitive, ce travail démontre que l'extraction automatique d'expressions temporelles a atteint un niveau de maturité technologique permettant son déploiement opérationnel dans de nombreux contextes applicatifs. Les modèles neuronaux basés sur les transformers offrent aujourd'hui des performances comparables à l'annotation humaine sur des textes formels, tout en conservant une capacité d'adaptation remarquable face à la diversité des styles d'écriture. Cependant, la route vers une extraction temporelle parfaite demeure jalonnée de défis scientifiques stimulants, notamment la compréhension fine des références temporelles implicites, la gestion des ambiguïtés sémantiques et la prise en compte des spécificités culturelles et linguistiques. Ces défis ouvrent la voie à de futures recherches qui continueront d'enrichir notre compréhension de la dimension temporelle du langage naturel.

Références

- [1] Almasian, S., Aumiller, D., & Gertz, M. (2021). *BERT got a Date : Introducing Transformers to Temporal Tagging*. arXiv preprint arXiv :2109.14927.
- [2] Ding, W., Gao, G., Shi, L., & Qu, Y. (2019). A Pattern-Based Approach to Recognizing Time Expressions. In *Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence (AAAI-19)*, pp. 6335–6342.
- [3] Mazur, P., & Dale, R. (2010). WikiWars : A New Corpus for Research on Temporal Expressions. In *Proceedings of the 2010 Conference on Empirical Methods in Natural Language Processing*, pp. 913–922, Cambridge, MA.
- [4] Strötgen, J., & Gertz, M. (2010). HeidelTime : High Quality Rule-based Extraction and Normalization of Temporal Expressions. In *Proceedings of the 5th International Workshop on Semantic Evaluation*, pp. 321–324, Uppsala, Sweden.
- [5] Su, X., Howard, P., & Bethard, S. (2025). Transformer-Based Temporal Information Extraction and Application : A Review. arXiv preprint arXiv :2504.07470.